


CSV : une ligne après l'autre



pour lire la catégorie, il faut parcourir chaque ligne en entier : les 9,4 Gio du fichier

Parquet : par groupes de lignes, puis par colonnes



pied de fichier : schéma, et pour chaque groupe et chaque colonne, min et max

une colonne se lit sans les autres ; un groupe dont le min et le max excluent le filtre ne se lit pas du tout

octets lus par Spark pour la même réponse (mesuré, échelle logarithmique)

